

# Flow Matching 与 Diffusion 项目阶段总结

从课程 Lab 到类别条件图像生成展示项目

RectifiedFlow-Lab

2026 年 6 月 5 日

## 项目结论

本项目包含两条主线：第一条是课程式 Lab，覆盖 ODE/SDE、Flow Matching、DDPM、CFG、Mini-DiT 与离散扩散；第二条是展示项目，从 CIFAR-10 U-Net Rectified Flow baseline 出发，经过采样消融、质量提升、DDPM/DDIM 强 baseline、EDM 与 Visual64 扩展，最终得到可展示的类别条件生成结果。当前最强 CIFAR-10 定量结果为 DDPM/DDIM cosine v-prediction U-Net: FID 13.37, IS 5.29; 最清晰的视觉展示来自 Visual64 Pets EDM。

## 目录

|                                                  |           |
|--------------------------------------------------|-----------|
| <b>1 总体架构</b>                                    | <b>2</b>  |
| <b>2 第一部分：课程 Lab 总结</b>                          | <b>2</b>  |
| 2.1 Lab 1: 概率路径、ODE 与 SDE                        | 2         |
| 2.2 Lab 2: 二维 Flow Matching                      | 3         |
| 2.3 Lab 3: Score Matching 与 DDPM                 | 5         |
| 2.4 Lab 4: MNIST 条件扩散与 CFG                       | 5         |
| 2.5 Lab 4.5: Mini-DiT 从零实现                       | 6         |
| 2.6 Lab 5: 快速采样、离散扩散与统一理论                        | 6         |
| <b>3 第二部分：展示项目阶段总结</b>                           | <b>7</b>  |
| 3.1 阶段 A: CIFAR-10 U-Net Rectified Flow Baseline | 7         |
| 3.2 阶段 B: NFE、Solver 与 Guidance 消融               | 9         |
| 3.3 阶段 C: Rectified Flow 质量升级                    | 10        |
| 3.4 阶段 D: DDPM/DDIM 强 Baseline                   | 11        |
| 3.5 阶段 E: EDM 与 Visual64 展示                      | 13        |
| <b>4 最终结果展示与结论</b>                               | <b>16</b> |

## 1 总体架构

项目目标不是只训练一个模型，而是把“理论路径、预测目标、网络结构、采样器、消融分析、展示结果”串成闭环。核心统一视角为

$$x_0 \sim p_0, \quad x_1 \sim p_{\text{data}}, \quad x_t = (1-t)x_0 + tx_1, \quad v_\theta(x_t, t, y) \approx x_1 - x_0.$$

这一路径解释了 Flow Matching 和 Rectified Flow；DDPM/EDM 分支则作为更强的图像质量 baseline，用于判断“问题来自理论目标、采样器，还是工程配置”。




图 1: 统一理论框架：连续扩散、Flow Matching、快速采样与离散扩散都可以放入概率路径和反向生成过程的视角下。图中箭头只表示直接依赖关系，避免跨层连线造成语义混淆。

## 2 第一部分：课程 Lab 总结

### 2.1 Lab 1: 概率路径、ODE 与 SDE

**理论基础** Lab 1 建立生成模型的基础语言：从简单分布到数据分布的概率路径、确定性 ODE 轨迹，以及随机 SDE 轨迹。ODE 强调确定性流映射，SDE 强调布朗运动和噪声驱动的分佈演化。

#### 关键代码

- `src/toy_data.py`: 构造二维 toy distribution。
- `src/ode.py`: Euler ODE 积分与轨迹模拟。
- `src/sde.py`: Brownian motion 和 SDE 采样。
- `labs/lab1/run_probability_path.py`、`labs/lab1/run_ode_sde.py`: 实验入口。




图 2: 概率路径从简单先验逐渐移动到目标数据分布。




图 3: ODE 与 SDE 的差异: ODE 轨迹平滑确定, SDE 轨迹包含随机扰动。

**结果分析** 概率路径图说明了生成模型的根本任务: 把  $p_0$  运输到  $p_{\text{data}}$ 。ODE/SDE 对比说明采样算法既可以通过确定性速度场完成, 也可以通过含噪反向过程完成。这为后续 Flow Matching 与 DDPM 的区别打下基础。

## 2.2 Lab 2: 二维 Flow Matching

**理论基础** Flow Matching 学习条件速度场, 而不是逐步预测噪声。在线性路径下:

$$x_t = (1-t)x_0 + tx_1, \quad u_t = x_1 - x_0, \quad \mathcal{L} = \|v_\theta(x_t, t) - u_t\|_2^2.$$

采样时解 ODE:  $\frac{dx}{dt} = v_\theta(x, t)$ 。

**关键代码**

- `src/flow_matching.py`: 构造  $(x_0, t, x_t, u_t)$  与 FM loss。
- `src/mlp.py`: 二维速度场 MLP。
- `src/samplers.py`: Euler、Heun 采样器。
- `labs/lab2/run_2d_flow_matching.py`: 训练、采样与可视化。




图 4: 二维 Flow Matching 从噪声生成目标分布，并通过 NFE 观察积分步数对质量的影响。




图 5: 轨迹和求解器对比展示了 ODE sampler 对最终生成分布的影响。

**结果分析** NFE 增大时，样本更接近目标分布；Heun 在低步数下通常比 Euler 更稳定。该 Lab 直接对应后续 CIFAR-10 项目中的 NFE、solver 和 runtime 消融。

### 2.3 Lab 3: Score Matching 与 DDPM

**理论基础** DDPM 通过前向加噪  $q(x_t|x_0)$  和反向去噪  $p_\theta(x_{t-1}|x_t)$  学习生成过程。训练常用噪声预测：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon, \quad \mathcal{L} = \|\epsilon_\theta(x_t, t) - \epsilon\|_2^2.$$

**关键代码**

- `src/diffusion.py`: DDPM schedule、前向加噪与反向采样。
- `labs/lab2/run_2d_ddpm.py`: 二维 DDPM 训练与采样。




图 6: DDPM 通过离散时间反向去噪生成样本，并与 Flow Matching 形成方法对照。

**结果分析** 前向加噪图展示数据逐渐退化为噪声；采样轨迹展示反向去噪恢复结构。与 Flow Matching 相比，DDPM 的训练目标更成熟，后续在 CIFAR-10 上成为更强的定量 baseline。

### 2.4 Lab 4: MNIST 条件扩散与 CFG

**理论基础** Classifier-Free Guidance 在训练时随机丢弃类别标签，使模型同时学习条件与无条件预测；采样时使用

$$\epsilon_{\text{cfg}} = \epsilon_{\text{uncond}} + w(\epsilon_{\text{cond}} - \epsilon_{\text{uncond}}).$$

更大的  $w$  增强类别一致性，但可能牺牲多样性并引入伪影。

**关键代码**

- `src/time_embedding.py`: 时间嵌入。
- `src/unet.py`: MNIST 条件 U-Net。
- `src/cfg_sampler.py`: CFG 采样。
- `labs/lab4/train_mnist_unet_cfg.py`、`labs/lab4/eval_cfg_scales.py`: 训练与 scale 对比。




图 7: MNIST 条件扩散验证了类别控制与 guidance scale 的影响。

**结果分析** 类别条件样本说明 U-Net 能根据数字标签控制生成结果。CFG scale 增大时数字类别更明确，但过高 scale 容易降低多样性。这个结论被迁移到 CIFAR-10 的 velocity guidance 与 DDPM/EDM CFG 实验。

## 2.5 Lab 4.5: Mini-DiT 从零实现

**理论基础** DiT 不是新的扩散目标，而是把 denoising network 从卷积 U-Net 换成 Transformer。图像被 patchify 成 token，经过 time/class conditioning 与 DiT block 后再 unpatchify 回图像空间。

### 关键代码

- `src/dit/patch_embed.py`: patchify 与 unpatchify。
- `src/dit/embeddings.py`: timestep 与 label embedding。
- `src/dit/dit_block.py`: AdaLN-Zero DiTBlock。
- `src/dit/model.py`: MiniDiT。
- `labs/lab_dit/train_mnist_dit.py`、`labs/lab_dit/compare_unet_dit.py`: 训练与对比。




图 8: Mini-DiT Lab 完成了从 patch token 到图像预测的完整训练与采样闭环。

**结果分析** 在 MNIST 小数据设置下，U-Net 依靠卷积归纳偏置更稳定；Mini-DiT 结构更通用，但需要更大数据和容量才能体现优势。因此展示项目没有在 U-Net baseline 尚不稳定时贸然扩展到 CIFAR-10 DiT。

## 2.6 Lab 5: 快速采样、离散扩散与统一理论

**理论基础** Lab 5 总结连续扩散与离散扩散。连续模型关注 ODE/SDE、velocity 或 score；离散扩散通过 mask corruption 定义 token 状态转移，再训练反向 denoiser。

### 关键代码

- `src/discrete_diffusion.py`: mask corruption 与离散转移。
- `src/discrete_denoiser.py`: toy sequence denoiser。
- `labs/lab5/02_run_mask_corruption.py`: 前向 mask corruption。

- labs/lab5/03\_train\_discrete\_denoiser.py、labs/lab5/04\_sample\_discrete\_denoiser.py: 离散 denoiser 训练与采样。
- src/theory\_plotting.py、labs/lab5/05\_make\_stage5\_figures.py: 统一理论图。




图 9: Stage 5 将连续生成模型和离散扩散模型放入统一总结中。

**结果分析** mask corruption 图显示 token 随  $t$  增大逐步被 mask; reverse process 展示 denoiser 如何从全 mask 恢复训练模式。统一理论图说明: DDPM、Flow Matching、Rectified Flow 和离散扩散的差异主要在路径、状态空间和预测函数。

### 3 第二部分：展示项目阶段总结

#### 3.1 阶段 A: CIFAR-10 U-Net Rectified Flow Baseline

**方法与改进** 展示项目首先落地类别条件 Rectified Flow。相比二维 toy Lab, 本阶段把  $x_t = (1-t)x_0 + tx_1$  扩展到 CIFAR-10 图像, 并使用 U-Net 预测 velocity field。类别标签通过 embedding 注入网络, 采样使用 Euler/Heun ODE solver。

##### 关键代码与配置

- src/cifar10\_dataset.py: CIFAR-10 dataloader, 归一化到  $[-1, 1]$ 。
- src/image\_flow\_matching.py: 图像 Rectified Flow tuple 与 loss。
- src/image\_unet.py: 类别条件 U-Net velocity network。
- labs/lab\_cifar\_flow/train\_cifar10\_unet\_fm.py: 训练入口。
- configs/cifar10\_unet\_fm.yaml: baseline 配置。




图 10: 进入长训前先检查数据、噪声、插值与保存逻辑，排除 pipeline bug。




图 11: 第一版 CIFAR-10 Rectified Flow 生成结果：已脱离纯噪声，但结构较糊。

**困难与解决** 主要困难是样本偏模糊，类别结构弱。我们先不急于扩展 Mini-DiT，而是做 debug 图确认真实图、噪声、插值和反归一化正确，避免把代码 bug 误判为模型问题。

**消融与结论** 第一阶段完成了训练闭环，但视觉质量不足。结论是：Rectified Flow baseline 可用于研究速度场和 ODE 采样，但还需要质量升级。

### 3.2 阶段 B: NFE、Solver 与 Guidance 消融

**方法与改进** 在同一个 U-Net Rectified Flow checkpoint 上，系统比较 NFE、Euler/Heun solver、CFG-like velocity guidance 和 runtime/memory。相比阶段 A，这一阶段从“能出图”升级为“能分析采样过

程”。




图 12: Phase 2 采样分析：质量、速度和类别控制之间存在明确 trade-off。

## 实验结果

**困难与解决** 低 NFE 容易产生不完整结构，高 guidance scale 可能放大伪影。解决方式是把低 NFE 作为速度分析，而不是质量判断；质量评估统一采用更高 NFE 和 Heun。

**消融结论** NFE=50/100 通常比 NFE=5 稳定；Heun 在低 NFE 下更平滑但计算更慢；guidance 能增强类别方向，但过强 guidance 会降低自然度。

### 3.3 阶段 C: Rectified Flow 质量升级

**方法与改进** 针对“图像仍然很糊”的问题，阶段 C 对 U-Net Rectified Flow 做质量升级：EMA、attention U-Net、更长训练、beta time sampling、data-end loss weighting、OT/minibatch pairing 和更大容量配置。相比阶段 B，这一阶段不再横向增加 sampler，而是集中提升生成能力。




图 13: Rectified Flow 质量升级带来可见改善，但仍未达到最终展示质量。

## 实验结果

**困难与解决** 训练 loss 已收敛但图仍糊，说明 MSE velocity loss 与视觉质量并不完全一致。我们通过 EMA 平滑权重、attention 增强全局建模、data-end weighting 强化靠近数据端的训练信号，并保留每次实验配置以便复现。

**消融结论** 100 epochs 明显优于 20 epochs，300 epochs 继续改善但边际收益下降；EMA 提升稳定性；time sampling 和 loss weighting 略有收益；但仅靠 Rectified Flow 继续堆 epoch 不是最优路线。因此项目转向更成熟的 DDPM/DDIM baseline。

### 3.4 阶段 D: DDPM/DDIM 强 Baseline

**方法与改进** 为了获得最终效果，阶段 D 使用 DDPM 训练目标、cosine schedule、v-prediction 和 DDIM 采样。相比 Rectified Flow 分支，DDPM/DDIM 的训练和采样更成熟，适合作为 CIFAR-10 定量主结果。

#### 关键代码

- labs/lab\_cifar\_flow/train\_cifar10\_ddpm\_unet.py

- labs/lab\_cifar\_flow/sample\_cifar10\_ddpm.py
- labs/lab\_cifar\_flow/eval\_cifar10\_ddpm\_metrics.py
- configs/cifar10\_unet\_ddpm\_cosine\_vpred\_500ep.yaml
- configs/cifar10\_final\_showcase\_cosine\_vpred\_upscaled.yaml



(a) 最终 CIFAR-10 DDPM/DDIM 样本

(b) 5k metric preview

图 14: DDPM/DDIM 成为 CIFAR-10 最强定量结果。

表 1: CIFAR-10 最终定量结果

| 模型                       | Sampler  | Samples | CFG | FID   | IS              |
|--------------------------|----------|---------|-----|-------|-----------------|
| DDPM cosine v-pred U-Net | DDIM 250 | 5000    | 2.5 | 13.37 | $5.29 \pm 0.14$ |
| EDM U-Net                | Heun 40  | 1000    | 2.0 | 41.50 | $5.01 \pm 0.48$ |

**困难与解决** DDPM 分支需要明确 schedule、prediction type、DDIM steps 和 CFG scale。通过 cosine v-prediction 与 500 epoch 训练，最终显著优于前面的 Rectified Flow 展示图。


**消融结论** cosine schedule + v-prediction 是当前 CIFAR-10 最强配置；DDIM 250 + CFG 2.5 在质量和计算成本之间取得较好平衡。

### 3.5 阶段 E: EDM 与 Visual64 展示

**方法与改进** EDM 分支引入预条件化、连续噪声尺度和 Karras Heun sampler。CIFAR-10 EDM 用于测试是否能超过 DDPM/DDIM；Visual64 Pets EDM 用于获得更清晰、更适合 README 的视觉展示。

#### 关键代码


- `src/edm.py`
- `labs/lab_cifar_flow/train_cifar10_edm_unet.py`
- `labs/lab_cifar_flow/sample_cifar10_edm.py`
- `labs/lab_visual64/train_visual64_edm_unet.py`
- `labs/lab_visual64/eval_visual64_sampling_sweep.py`
- `configs/visual64_pets_binary_edm_300ep.yaml`



(a) CIFAR-10 EDM 300ep

(b) EDM metric preview



图 15: CIFAR-10 EDM 相比早期 EDM 更连贯，但未超过 DDPM/DDIM。



(a) Binary Pets

(b) 37-class Pets

图 16: Visual64 Pets EDM 是当前最清晰的视觉结果。

**Visual64 EDM Pets: binary cats vs dogs****Visual64 EDM Pets: 37-class fine-grained samples****图 17:** 最终展示图：Visual64 Pets EDM, Heun 80 steps, CFG 2.0。

**困难与解决** CIFAR-10 32x32 图像本身展示冲击力有限, EDM 定量也没有超过 DDPM/DDIM。解决方式是保留 DDPM/DDIM 作为 CIFAR-10 metric 主结果, 同时用 64x64 Pets EDM 作为视觉主展示。

**消融结论** Visual64 sampling sweep 显示 CFG 2.0 和 Heun 80 steps 更稳；CFG 3.0 没有明显收益且更容易牺牲自然度；30/50 steps 可用，但 80 steps 细节更稳定。

## 4 最终结果展示与结论

表 2: 最终项目交付物

| 模块                   | 代表文件                             | 结论                                             |
|----------------------|----------------------------------|------------------------------------------------|
| 课程 Lab               | labs/lab1-labs/lab5              | 完成从 ODE/SDE 到离散扩散的理论与代码闭环。                     |
| Mini-DiT             | src/dit/, labs/lab_dit           | 完成 patchify、AdaLN DiTBlock、MNIST 训练与 U-Net 对比。 |
| CIFAR Rectified Flow | src/image_flow_matching.py       | 适合研究 velocity、NFE、solver、guidance，但最终图像仍偏糊。    |
| CIFAR DDPM/DDIM      | train_cifar10_ddpm_unet.py       | 最强 CIFAR-10 定量结果：FID 13.37, IS 5.29。           |
| CIFAR/Visual EDM     | src/edm.py,<br>labs/lab_visual64 | Visual64 Pets EDM 是最清晰的展示结果。                   |

### 最终判断

项目最终形成了清晰的研究叙事：先用课程 Lab 建立统一理论，再用 CIFAR-10 Rectified Flow 验证 velocity field 与 ODE sampling，发现图像质量瓶颈后通过 EMA、attention、time sampling 和 loss weighting 改进；当 Rectified Flow 仍不足以达到最终展示效果时，转向 DDPM/DDIM 与 EDM。最终保留 DDPM/DDIM 作为 CIFAR-10 定量主结果，Visual64 EDM 作为视觉主结果。

## 复现实验入口

```
# CIFAR-10 final DDPM/DDIM samples
conda run -n fm_diffusion python labs/lab_cifar_flow/sample_cifar10_ddpm.py \
    --config configs/cifar10_final_showcase_cosine_vpred_upscaled.yaml

# CIFAR-10 final metrics
conda run -n fm_diffusion python labs/lab_cifar_flow/eval_cifar10_ddpm_metrics.py \
    --config configs/cifar10_metrics_final_cosine_vpred_5k.yaml

# Visual64 final panel
python labs/lab_visual64/make_final_visual64_showcase.py
```